

# DETECCIÓN DEL FRAUDE EN TRANSACCIONES DE TARJETAS DE CRÉDITO

ANÁLISIS EXPLORATORIO DE DATOS (EDA).

BOOTCAMPO DE DATA SCIENCE EN THE BRIDGE. REALIZADO POR CARMEN GÓMEZ  
GARCÍA-ATANCE Y MARÍA JESÚS SÁNCHEZ PIMENTA. 2025/2026.



# ÍNDICE

Introducción y contexto

Elección de la temática y obtención de los datos

Definición de hipótesis

Preprocesado de los datos

Limpieza de datos

Análisis Exploratorio de Datos

Verificación de hipótesis

Conclusiones

Recomendaciones y próximos pasos



# 1. Introducción y contexto

¿Por qué es un problema relevante?

Impacto económico y reputacional

Necesidad de detección en tiempo real

Fraude = eventos raros

El gran reto: datos desbalanceados



Solo el 0,17 % de las transacciones son fraude

- ➡ Riesgo de conclusiones engañosas
- ➡ Dificultad para detectar patrones



# 1. Introducción y contexto

## OBJETIVOS

Comprender la estructura del dataset

Analizar el desbalanceo de la variable objetivo

Identificar patrones relevantes

Sentar las bases para modelado futuro

## ALCANCE DEL PROYECTO

INCLUYE	NO INCLUYE
<ul style="list-style-type: none"><li>Análisis Exploratorio de Datos</li><li>Estadística descriptiva</li><li>Visualización</li></ul>	<ul style="list-style-type: none"><li>Entrenamiento de modelos</li><li>Evaluación predictiva</li></ul>



## 2. Elección de la temática y obtención de los datos

¿Cómo se eligieron los datos?

Enfoque B

Exploración previa de datasets

Selección por relevancia real

DATASET

284.807 transacciones

492 fraudes

Septiembre de 2013

Dos días de transacciones

31 variables

31 variables

V1–V28

Time

Amount

Class

Componentes PCA  
(anonimizadas)

Variable  
objetivo



### 3. Definición de hipótesis

1. Existen patrones diferenciados
2. El importe está relacionado con el fraude
3. El fraude es multivariante



### 3. Definición de hipótesis


#### HIPÓTESIS INICIALES



Existen patrones  
diferenciados




El importe está  
relacionado con el  
fraude




El fraude es  
multivariante

## 4. Preprocesado de los datos



## 5. Limpieza de datos



## 5. Limpieza de datos

Valores faltantes

→ No se detectaron en ninguna de las variables

Duplicados

→ 1.081 filas duplicadas eliminadas

→ Prevención de sesgos


→ Mejora de la calidad del análisis



## 5. Limpieza de datos

Outliers

- Más fraude entre outliers
- No se eliminan
- Se transforman




## 6. Análisis Exploratorio de Datos



## 6. 1. Análisis Univariante

Class


Evidencia un desbalanceo extremo



El 99,83 % de las transacciones son legítimas

Amount


Distribución altamente asimétrica con cola derecha pronunciada



## 6. 1. Análisis Univariante

Time

Distribución no uniforme



V1-V28


Distribuciones centradas en torno a cero, coherentes con la aplicación de PCA



## 6. 1. Análisis Univariante

Amount


La transformación logarítmica de esta variable redujo significativamente su asimetría, facilitando su análisis.



## 6. 2. Análisis Bivariante

Se analizaron relaciones entre pares de variables, prestando especial atención a la relación con la variable objetivo.

Amount\_log vs Class




El fraude no se limita a importes altos

## 6. 2. Análisis Bivariante

Time vs Class

No hay patrón temporal claro




Correlaciones con Class

Ninguna variable PCA explica el fraude por sí sola

## 6.3. Análisis Multivariante

### Matriz de correlación

→ No se identificaron correlaciones lineales fuertes ni multicolinealidad significativa




↓  
Las variables aportan información complementaria


## 6.3. Análisis Multivariante

Proyecciones PCA (2D y 3D)

Las transacciones fraudulentas aparecen solapadas con las legítimas




Scatter 3D (V1, V2, V3) coloreado por Class (muestra)



## 6.3. Análisis Multivariante

Pairplots de variables  
relevantes

Confirman la ausencia de  
patrones simples y la  
complejidad del problema.



## 7. Verificación de hipótesis

Hipótesis 1

Las transacciones fraudulentas presentan patrones diferenciados respecto a las legítimas en algunas variables.



Parcialmente cumplida

Hipótesis 2

El importe de la transacción está relacionado con la probabilidad de fraude.



Refutada

Hipótesis 3

El fraude no puede explicarse mediante una única variable, sino mediante la combinación de varias



Confirmada

## 8. Conclusiones

Fraude raro y complejo

No hay reglas simples

Necesidad de enfoque multivariante

## 8. Conclusiones

INSIGHT	VALOR
Porcentaje de fraude total	0,17%
Mediana Amount No Fraude	22,0
Mediana Amount Fraude	9,82
Porcentaje de outliers en Amount	11.17%
Variables más correlacionadas con Class	V17, V14, V12, V10


El EDA sirve como base para una detección de fraude robusta

## 9. Recomendaciones y próximos pasos

Se recomienda:

- Modelos sensibles al desbalanceo
- Métricas adecuadas
- Selección de variables

# Desenmascarando el Fraude



**FIN**

¡Esperamos que os haya gustado!



Esta foto de Autor desconocido está bajo licencia [CC BY-NC-ND](#)